


하드웨어 시스템



Single Node
GPU Server

Mater/Worker node(GPU node)

1. Gigabyte GPU Server G493-SB1-AAP1
2. CPU : XEON(R) GOLD 6530
3. CPU cores : 2 Socker, 32C/64T -> **128 cores**
4. Memory : 512 GB
5. Storage : SSD 1TB(RAID1, OS), SSD 7TB(data)




GPU : 4개 장착 됨

1. NVIDIA L40S
2. GPU 아키텍처 : NVIDIA Ada Lovelace Architecture
3. CUDA 병렬 처리 코어 : 18,176
4. 단정도 성능(FP32) : 91.6테라플롭스
5. GPU 메모리 : ECC 포함 **48GB GDDR6**
6. 전력 소비량 : 최대 350W(구성 가능)

GPU Server 운영 인프라

DeepcellKube AI Toolkit 주요 구성 요소



Kubernetes 기반의 AI Platform

- **Kubernetes** : 멀티 노드 클러스터 인프라
- **Kubernetes 기반의 Kubeflow** : AI 연구 개발을 위한 사용자들에게 Container(가상 시스템)를 제공
- **AI Platform** : AI, ML, DL를 위한 개발환경부터 서비스까지 **전체 워크플로를 관리하고 운영할 수 있는 통합 솔루션**을 제공

Kubeflow


Kubeflow의 주요 프로젝트

 Kubeflow SPARK OPERATOR Kubeflow Spark Operator Kubeflow Spark Operator aims to make specifying and running Spark applications as easy and idiomatic as running other workloads on Kubernetes.	 Kubeflow NOTEBOOKS Kubeflow Notebooks Kubeflow Notebooks lets you run web-based development environments on your Kubernetes cluster by running them inside Pods.	 Kubeflow TRAINER Kubeflow Trainer Kubeflow Trainer is a Kubernetes-native project for LLMs fine-tuning and enabling scalable, distributed training across a wide range of AI frameworks, including PyTorch, HuggingFace, DeepSpeed, MLX, JAX, XGBoost, and others.	 Katib Kubeflow Katib Kubeflow Katib is a Kubernetes-native project for automated machine learning (AutoML) with support for hyperparameter tuning, early stopping and neural architecture search.
 KServe Kubeflow KServe KServe is a standardized distributed generative and predictive AI inference platform for scalable, multi-framework deployment on Kubernetes.	 Kubeflow MODEL REGISTRY Kubeflow Model Registry Kubeflow Model Registry is a cloud-native component that provides a single pane of glass for ML model developers to index and manage models, versions, and ML artifacts metadata. It fills a gap between model experimentation and production activities.	 Kubeflow Pipelines Kubeflow Pipelines (KFP) is a platform for building then deploying portable and scalable machine learning workflows using Kubernetes.	 Kubeflow Dashboard Kubeflow Central Dashboard is our hub which connects the authenticated web interfaces of Kubeflow and other ecosystem components.

Central Dashboard

- Kubeflow 사용을 위한 기본 Web UI
- 사용자 인증 후 사용 가능
- Kubeflow 컴포넌트 UI제공

(default 사용자: testuser / qwer)



Notebooks


- 웹기반 개발환경 (구글의 colab 파이썬과 유사한 환경)
- **JupyterLab**, RStudio, and Visual Studio Code (code-server) 지원
- 개발 환경을 클러스터에 컨테이너로 생성

The diagram illustrates the process of accessing a JupyterLab environment through Kubeflow. On the left, a screenshot of the Kubeflow 'Notebooks' page shows a table with columns: Status, Name, Type, Created at, Last activity, Image, GPUs, CPUs, and Memory. A notebook named 'torch-gpu-test' is listed with a green status icon. A blue box labeled '상태표시:실행중' (Status: Running) points to this icon. Another blue box labeled '연결' (Connect) points to the 'CONNECT' button in the 'Actions' column. A large blue arrow points from this screenshot to a screenshot of the JupyterLab interface on the right. The JupyterLab interface shows a terminal window with the following output:

```
[1]: import torch
[2]: torch.cuda.is_available()
[3]: True
[4]: torch.cuda.device_count()
[5]: 1
[6]: torch.cuda.get_device_name()
[7]: "NVIDIA L40S"
```

KServe

- AI Inference Platform
- 일반 딥러닝, 머신러닝 Inference Service 구축 지원
- 생성형 AI, LLM Inference Service 구축 지원
- 다양한 AI 프레임워크 지원



DeepcellKube User Manager

Kubeflow를 위한 사용자 관리 솔루션

전체 사용자 조회



 홈
 사용자 추가
 사용자 대량추가
 사용자 상세보기
 사용자 목록

Kubeflow 사용자 목록

UID	메일	이름	휴대폰	상태	삭제
blue	blue@deepcell.co.kr	장우진	010-5554-9764	상세보기	삭제
dcku	dcku@deepcell.kr	김철수	010-1234-4567	상세보기	삭제
blue1	bbblue1@deepcell.co.kr	장우영	010-5554-9764	상세보기	삭제
blue2	bbblue2@deepcell.co.kr	장우진	010-5554-9764	상세보기	삭제
blue3	bbblue3@deepcell.co.kr	장우영	010-5554-9764	상세보기	삭제
blue4	bbblue4@deepcell.co.kr	장우진	010-5554-9764	상세보기	삭제
blue5	bbblue5@deepcell.co.kr	장우영	010-5554-9764	상세보기	삭제
jskim	jskim@deepcell.co.kr	김준성	010-8727-8107	상세보기	삭제
npark	npark@starcell.co.kr	박노현	010-8727-8107	상세보기	삭제
sales	sales@ecpg.co.kr	에프케이지	010-2259-5642	상세보기	삭제
gghong	hong@deepcell.co.kr	홍길동	010-8727-8107	상세보기	삭제
jskim1	sjkim1@deepcell.co.kr	김준호	010-8727-8107	상세보기	삭제

Copyright
©2024 Starcell Inc.
sales@starcell.co.kr

사용자 정보 수정



 홈
 사용자 추가
 사용자 대량추가
 사용자 상세보기
 사용자 목록

Kubeflow 사용자 상세정보

UID	blue
메일	blue@deepcell.co.kr
이름	장우진
휴대전화	010-5554-9764
CPU	20
메모리	40Gi
GPU	6
PVC	10
스토리지	50Gi

[사용자 정보 수정](#) [재설정](#)

Copyright
©2024 Starcell Inc.
sales@starcell.co.kr

사용자 추가



 홈
 사용자 추가
 사용자 대량추가
 사용자 상세보기
 사용자 목록

Kubeflow 사용자 추가

사용자 이름 입력

This value is not valid

휴대전화 번호 입력

This value is not valid

사용자 ID 입력(uid)

This value is not valid

메일 주소 입력(email)

This value is not valid

비밀번호 입력

This value is not valid

비밀번호 확인

This value is not valid

CPU 할당량 입력

Memory 할당량 입력

스토리지 클레이드 입력

스토리지 할당량 입력

GPU 할당량 입력

[사용자 추가](#)

Copyright
©2024 Starcell Inc.
sales@starcell.co.kr

사용자 대량추가



 홈
 사용자 추가
 사용자 대량추가
 사용자 상세보기
 사용자 목록

사용자 대량추가

CSV(comma-separated variables) 파일을 이용하여 사용자 계정을 대량으로 만들 수 있습니다.
아래에서 생성할 사용자 계정 정보를 저장한 CSV 형식의 파일을 업로드 하세요.

파일을 이곳으로 드래그하거나 파일선택 버튼을 클릭하세요

[파일선택](#)

선택된 CSV파일이 없습니다.

Copyright
©2024 Starcell Inc.
sales@starcell.co.kr

 Starcell

15

 Deepcell

Notebooks를 이용한 개발 환경 활용

Jupyter Notebook을 이용

- 코딩 실습 교육
- 머신 러닝 실습 교육
- 딥러닝 실습 교육
- API 프로그램 교육

Terminal을 이용

- Linux OS 실습
- Shell Script 실습

VS Code 이용

- 기타 개발 실습

R-studio 이용

- 데이터 분석

Kserve를 이용한 LLM Service 구축 활용

LLM 서비스 구축

- qwen 등 경량 LLM 서비스 구축

OpenAI-Compatible APIs 지원

- 챗GPT와 같은 AI 서비스 개발 실습
- 챗봇 개발 실습

GPU 분할을 통한 효율적 사용

NVIDIA GPU의 분할 사용 방법

NVIDIA GPU는 하나의 GPU를 그대로 사용하는 방법과 물리적으로 분할해서 사용하는 방법 그리고 논리적으로 공유해서 사용하는 방법들을 제공

분할방법	방법 설명	제공 시스템	장점	단점
MIG (Multi GPU Instance)	GPU에서 제공하는 기능으로 GPU 자원(GPU, GPU Mem ory)을 물리적으로 분할하여 사용	A100, H100, H200, Pro 600 0 등 최신 아키텍처 또는 Datacenter용 GPU에서 지원됨	물리적으로 분할 되어서 분할 영역이 고립됨, 따라서 분할 된 영역이 영향을 주고 받지 않으므로 안정적으로 사용 가능	특정 GPU에서만 사용 가능 정해진 규격(프로파일)으로만 분할 가능 최대 7개로 분할 가능(GPU 모델에 따라 분할 가능 인스턴스 수가 다름) 미리 분할해 놓고 사용해야 함
MPS (Multi Process Service)	하나의 GPU를 여러 개의 프로그램이 사용할 수 있도록 소프트웨어적으로 제어하는 방법	Volta 아키텍처 이후의 모든 NVIDIA GPU에서 지원됨	특별한 하드웨어 요구사항 없이 소프트웨어적인 설정으로 GPU를 분할하여 사용 컨트롤 프로세스에 의해 GPU 오류를 감지하여 오류의 확산을 방어함	GPU를 물리적으로 완전히 고립시키지 못함
Time-Slicing	하나의 GPU를 여러 개의 프로그램이 시용할 수 있도록 시분할 방식을 제공	Pascal 아키텍처 이후의 모든 NVIDIA GPU에서 지원됨	가장 간단하게 설정하여 GPU를 분할 사용할 수 있는 방법	Context Switching이 빈번하게 발생하여 성능 저하가 큼 메모리 보호 기능이 가장 약하여 오류 발생 시 같은 GPU를 사용하는 다른 프로그램에 영향을 많이 미침



GPU 분할을 통한 효율적 사용

NVIDIA GPU Operator

- The (optional) ability to install NVIDIA drivers on the host
- The Kubernetes device plugin for GPUs
- The (optional) ability to configure NVIDIA Container Runtime on the host
- Automatic node labeling
- DCGM (Data Center GPU Manager) based monitoring and more

The NVIDIA device plugin is a Daemonset that allows you to automatically:

- Expose the number of GPUs on each node of your cluster
- Keep track of the health of your GPUs
- Run GPU-enabled containers in your Kubernetes cluster



Automated by GPU Operator

GPU 분할을 통한 효율적 사용

MPS (Multi-Process Service)를 이용한 고밀도 분할

- MPS는 하나의 GPU에서 여러 프로세스가 동시에 연산할 수 있도록 돕는 기술
- 구성 개념: 4개의 물리 GPU를 총 32개의 가상 GPU로 확장 (GPU 당 8개 분할 × 4장 = 32개 슬롯).
- 각 가상 GPU는 물리 GPU 메모리의 약 1/8 정도를 공유하며, MPS를 통해 컨텍스트 스위칭 오버헤드를 줄여 동시 실행 성능을 높인다.
- 특징: 동일 정책 적용: 기본적으로 단일 노드 내의 모든 GPU에는 동일한 ConfigMap(분할 정책)이 적용됩니다. (예: 모든 GPU를 8등분)
- 용도: 메모리 사용량이 적은 기초 딥러닝 실습, 추론(Inference) 수업, 간단한 파이썬 연산 실습.

Time-Slicing을 통한 GPU 분할

- Kubernetes 환경에서 GPU를 나누어 쓰는 가장 범용적인 방법. 물리적으로 GPU를 쪼개는 것이 아니라, 시간을 나누어(Time-Slicing) 여러 컨테이너가 GPU를 번갈아 가며 사용.
- 작동 원리: 소프트웨어적으로 하나의 GPU를 여러 개의 Replica로 둔갑시켜 Kubernetes 스케줄러를 속입니다. 실제 연산은 GPU 내부 스케줄러에 의해 시분할로 처리됩니다.
- 장점: 하드웨어 제약(MIG 지원 여부 등) 없이 모든 NVIDIA GPU에서 사용 가능합니다. 설정이 간편하고, 오버헤드가 크지 않아 교육용 환경에 적합합니다.
- 주의점: 메모리 격리가 완벽하지 않아, 한 사용자가 GPU 메모리를 100% 써버리면(OOM), 같은 GPU를 공유하는 다른 사용자에게 영향을 줄 수 있습니다

GPU서버 접속 방법

[GPU서버 접속 방법]

웹브라우저에서 다음 URL 로 접속합니다. (학내망에서는 일반 http, https는 전체 접속 가능함)

● <https://kubeflow.deepcell.co.kr>

브라우저에 로그인 화면이 나타나면 "Login with OpenLDAP"을 선택하여 testuser / qwer 로 로그인합니다.

다만, 먼저 PC 의 hosts 파일에 다음과 같은 내용을 추가하여 사용해야 합니다.

hosts 파일 위치: `C:\Windows\System32\drivers\etc`

1. kubeflow central dashboard : <https://kubeflow.deepcell.co.kr>

220.90.190.241 kubeflow.deepcell.co.kr